



ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO CHUYÊN ĐỀ TỐT NGHIỆP

NGÀNH CÔNG NGHỆ THÔNG TIN

XÂY DỰNG TRỢ LÝ ẢO THÔNG MINH DỰA TRÊN RAG HỖ TRỢ DẠY VÀ HỌC
MÔN SINH HỌC TẠI CÁC TRƯỜNG TRUNG HỌC CƠ SỞ
RAG-BASED INTELLIGENT VIRTUAL ASSISTANT FOR BIOLOGY EDUCATION
IN SECONDARY SCHOOLS.

LÊ CHÂU ĐĂNG KHOA
24210219@ms.uit.edu.vn

Giảng viên hướng dẫn: ThS. Nguyễn Hữu Quyền

TP Hồ Chí Minh, 2026



ĐẠI HỌC QUỐC GIA HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN

BÁO CÁO CHUYÊN ĐỀ TỐT NGHIỆP

NGÀNH CÔNG NGHỆ THÔNG TIN

XÂY DỰNG TRỢ LÝ ẢO THÔNG MINH DỰA TRÊN RAG HỖ TRỢ DẠY VÀ HỌC
MÔN SINH HỌC TẠI CÁC TRƯỜNG TRUNG HỌC CƠ SỞ
RAG-BASED INTELLIGENT VIRTUAL ASSISTANT FOR BIOLOGY EDUCATION
IN SECONDARY SCHOOLS.

LÊ CHÂU ĐĂNG KHOA
24210219@ms.uit.edu.vn

Giảng viên hướng dẫn: **ThS. Nguyễn Hữu Quyền**

TP Hồ Chí Minh, 2026

LỜI CẢM ƠN

Để hoàn thành báo cáo chuyên đề tốt nghiệp này, em đã nhận được sự quan tâm, giúp đỡ và hướng dẫn tận tình từ rất nhiều quý thầy cô, Nhà trường, Trung tâm Phát triển Công nghệ Thông tin (CITD), gia đình và bạn bè.

Đầu tiên, em xin gửi lời cảm ơn sâu sắc nhất đến thầy **ThS. Nguyễn Hữu Quyền** đã tận tâm định hướng, chỉ bảo và cung cấp cho em những kiến thức quý báu trong suốt quá trình nghiên cứu và thực hiện đề tài. Sự nhiệt tình và những lời khuyên hữu ích của thầy là động lực to lớn giúp em vượt qua nhiều khó khăn trong quá trình làm báo cáo.

Em xin trân trọng gửi lời cảm ơn đến Ban Giám hiệu Nhà trường, Trung tâm Phát triển Công nghệ Thông tin (CITD) đã tạo điều kiện học tập, nghiên cứu thuận lợi trong suốt quá trình em theo học. Em cũng xin gửi lời cảm ơn chân thành đến toàn thể Quý thầy cô trong Khoa đã trực tiếp giảng dạy, truyền đạt cho em những kiến thức chuyên môn nền tảng vững chắc trong suốt những năm học qua. Đó là hành trang vô giá để em có thể tiếp cận và vận dụng những công nghệ mới như Trí tuệ nhân tạo, Mô hình ngôn ngữ lớn (LLM) và RAG vào thực tiễn.

Cuối cùng, em xin bày tỏ lòng biết ơn sâu sắc đến gia đình và bạn bè, những người luôn bên cạnh động viên, ủng hộ và tạo mọi điều kiện tốt nhất để em yên tâm học tập và nghiên cứu.

Mặc dù đã có nhiều cố gắng hoàn thiện báo cáo, nhưng do giới hạn về mặt thời gian cũng như kinh nghiệm thực tiễn, chắc chắn báo cáo không tránh khỏi những thiếu sót. Em rất mong nhận được những nhận xét, góp ý quý báu từ quý thầy cô để báo cáo và hệ thống được hoàn thiện hơn nữa.

Một lần nữa, em xin chân thành cảm ơn!

Sinh viên thực hiện

NỘI DUNG

LỜI CẢM ƠN	i
DANH SÁCH HÌNH ẢNH	iii
DANH SÁCH BẢNG BIỂU	v
DANH MỤC TỪ VIẾT TẮT	vi
DANH MỤC THUẬT NGỮ	vii
TÓM TẮT	1
1 TỔNG QUAN ĐỀ TÀI	3
1.1 Bối cảnh và tính cấp thiết	3
1.2 Mục tiêu của đề tài	4
1.3 Đối tượng và phạm vi nghiên cứu	5
1.3.1 Đối tượng nghiên cứu	5
1.3.2 Phạm vi nghiên cứu	5
1.4 Cấu trúc của báo cáo	6
2 CƠ SỞ LÝ THUYẾT	7
2.1 Tổng quan về Xử lý ngôn ngữ tự nhiên và Trí tuệ nhân tạo tạo sinh	7
2.2 Mô hình ngôn ngữ lớn (Large Language Models - LLMs)	8
2.2.1 Kiến trúc Transformer	8
2.2.2 Họ mô hình Qwen	8
2.3 Sinh văn bản tăng cường truy xuất (RAG)	9
2.3.1 Hạn chế của LLM truyền thống	9
2.3.2 Nguyên lý hoạt động của RAG	9
2.4 Nhúng (Embedding) và Cơ sở dữ liệu Vector	10
2.4.1 Khái niệm Embedding	10
2.4.2 Cơ sở dữ liệu Vector (ChromaDB)	10
2.5 Xử lý Đa phương thức (Multi-modal) trong RAG	11
2.5.1 Mô hình trích xuất và gán nhãn ảnh	11

3	PHƯƠNG PHÁP THỰC HIỆN VÀ KIẾN TRÚC HỆ THỐNG	12
3.1	Kiến trúc tổng thể hệ thống	12
3.2	Quy trình thu thập và xử lý dữ liệu (ETL Pipeline)	12
3.2.1	Xử lý Dữ liệu Văn bản (Text ETL)	14
3.2.2	Xử lý Dữ liệu Hình ảnh (Image ETL)	14
3.3	Luồng truy xuất và sinh văn bản (RAG Pipeline)	15
3.3.1	Định tuyến theo ý định truy vấn (Query Intent Routing)	15
3.3.2	Truy xuất lai và cơ chế lọc liên quan (Hybrid Retrieval & Relevance Gate)	15
3.4	Thiết kế giao diện người dùng (Frontend)	17
3.4.1	Một số giao diện tiêu biểu	17
4	THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN	20
4.1	Môi trường và công cụ thực nghiệm	20
4.2	Bộ dữ liệu tri thức đã số hóa và lập chỉ mục	21
4.3	Xây dựng bộ dữ liệu kiểm thử (Testsets)	22
4.3.1	Nguyên lý gắn nhãn nguồn (ground truth)	23
4.3.2	Quy trình sinh dữ liệu tự động	23
4.4	Phương pháp và độ đo đánh giá	25
4.4.1	Đánh giá pha truy xuất (Retrieval Evaluation)	25
4.4.2	Đánh giá pha sinh ngôn ngữ (LLM-as-a-judge)	26
4.4.3	Điểm tổng hợp và xếp hạng	27
4.5	Kết quả thực nghiệm	28
4.5.1	Xếp hạng tổng thể 12 bộ sách	29
4.5.2	Phân tích Recall@k: ảnh hưởng của số đoạn truy xuất	30
4.5.3	Chất lượng câu trả lời sinh ra	32
4.6	Thảo luận kết quả	33
4.6.1	Đánh giá thủ công luồng đa phương thức	34
4.6.2	Ưu điểm	34
4.6.3	Hạn chế	34
5	KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN	36
5.1	Kết luận	36
5.2	Hạn chế của đề tài	37
5.3	Hướng phát triển tương lai	37
	TÀI LIỆU THAM KHẢO	45

DANH SÁCH HÌNH ẢNH

2.1	Sơ đồ nguyên lý hoạt động cơ bản của hệ thống RAG	9
3.1	Sơ đồ kiến trúc tổng thể của hệ thống Trợ lý ảo RAG	13
3.2	Luồng xử lý truy vấn RAG Đa phương thức trong Backend	16
3.3	Các màn hình chính của giao diện trợ lý ảo Sinh học.	18
3.4	Chi tiết hình ảnh minh họa Sinh học kèm trích dẫn trang sách gốc do hệ thống trả về.	19
4.1	Luồng đánh giá tự động: câu hỏi đi qua đúng pipeline RAG thật (truy xuất → Qwen2.5 sinh câu trả lời), sau đó được đo bằng độ đo IR và mô hình giám khảo thứ hai.	28
4.2	Xếp hạng tổng thể 12 bộ sách theo điểm overall.	30
4.3	Hai thành phần điểm tổng thể: điểm truy xuất so với điểm câu trả lời theo từng bộ sách.	30
4.4	Recall trung bình tăng đơn điệu theo k , so với cấu hình production.	31
4.5	Recall@ k theo từng bộ sách — k càng lớn, recall càng cao ở mọi bộ sách.	32
4.6	Chất lượng câu trả lời của Qwen2.5 do LLM thứ hai (MiMo-v2.5-pro) chấm.	33

DANH SÁCH BẢNG BIỂU

4.1	Cấu hình môi trường và ngăn xếp công nghệ thực nghiệm	21
4.2	Thống kê bộ dữ liệu tri thức đã số hóa và lập chỉ mục theo từng bộ sách	22
4.3	Phân bố 12 bộ dữ liệu kiểm thử theo cuốn sách	24
4.4	Một số câu hỏi kiểm thử tiêu biểu kèm nhãn nguồn	25
4.5	Các độ đo trung bình trên toàn bộ 120 câu hỏi (12 bộ sách)	29
4.6	Bảng xếp hạng tổng thể 12 bộ sách (judge: MiMo-v2.5-pro)	29
4.7	Recall@k (thô) theo từng bộ sách so với recall production	31

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Từ tiếng Anh	Từ tiếng Việt / Giải nghĩa
AI	Artificial Intelligence	Trí tuệ nhân tạo
LLM	Large Language Model	Mô hình ngôn ngữ lớn
RAG	Retrieval-Augmented Generation	Sinh văn bản tăng cường truy xuất
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
VQA	Visual Question Answering	Hỏi đáp trực quan
OCR	Optical Character Recognition	Nhận dạng ký tự quang học
THCS	-	Trung học cơ sở
SGK	-	Sách giáo khoa
KHTN	-	Khoa học tự nhiên
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
API	Application Programming Interface	Giao diện lập trình ứng dụng

DANH MỤC THUẬT NGỮ

Thuật ngữ tiếng Anh	Thuật ngữ tiếng Việt tương đương
Embedding	Nhúng (Quá trình chuyển đổi dữ liệu thành vector số học)
Vector Database	Cơ sở dữ liệu Vector
Prompt	Câu lệnh / Câu nhắc (Đầu vào của mô hình ngôn ngữ)
Hallucination	Hiện tượng ảo giác (Sinh thông tin sai lệch của AI)
Chunking	Phân mảnh (Cắt nhỏ văn bản thành các đoạn)
Information Retrieval	Truy xuất thông tin
Fine-tuning	Tinh chỉnh mô hình
Generative AI	Trí tuệ nhân tạo tạo sinh

TÓM TẮT

Trong những năm gần đây, sự phát triển mạnh mẽ của Trí tuệ nhân tạo (AI), đặc biệt là các Mô hình ngôn ngữ lớn (Large Language Models - LLMs) đã mở ra nhiều cơ hội mới trong việc ứng dụng công nghệ vào lĩnh vực giáo dục. Tuy nhiên, việc áp dụng trực tiếp các mô hình LLM vào giáo dục phổ thông, đặc biệt là môn Sinh học cấp trung học cơ sở, vẫn gặp nhiều khó khăn do hiện tượng ảo giác (hallucination) - sinh ra thông tin sai lệch - và sự thiếu hụt kiến thức đặc thù, cập nhật theo chương trình sách giáo khoa trong nước.

Để giải quyết vấn đề này, báo cáo chuyên đề tốt nghiệp này đề xuất và phát triển một hệ thống trợ lý ảo thông minh ứng dụng kỹ thuật sinh văn bản tăng cường truy xuất (Retrieval-Augmented Generation - RAG [26]) nhằm hỗ trợ việc dạy và học môn Sinh học cấp trung học cơ sở. Hệ thống kết hợp sức mạnh của mô hình ngôn ngữ lớn Qwen2.5-3B-Instruct [40] cùng với khả năng truy xuất thông tin từ cơ sở dữ liệu vector ChromaDB, nơi lưu trữ tri thức được trích xuất trực tiếp từ 12 bộ sách giáo khoa Khoa học tự nhiên lớp 6, 7, 8, 9 của ba nhà xuất bản (Kết nối tri thức với cuộc sống, Chân trời sáng tạo, Cánh diều), với trọng tâm là phần kiến thức Sinh học. Đặc biệt, hệ thống được thiết kế với hai luồng xử lý riêng biệt: một luồng xử lý văn bản (sử dụng mô hình nhúng sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2) và một luồng xử lý hình ảnh (sử dụng clip-vit-base-patch16 và Vintern-1B-v2) giúp hệ thống có khả năng hiểu và truy xuất cả nội dung văn bản lẫn hình ảnh sơ đồ, biểu đồ đặc thù của môn Sinh học.

Về mặt người dùng, hệ thống cung cấp một giao diện web trực quan, thân thiện được xây dựng bằng Next.js, cho phép học sinh tương tác, đặt câu hỏi và nhận được câu trả lời chính xác, kèm theo trích dẫn nguồn hình ảnh, trang sách cụ thể. Hệ thống được đánh giá định lượng trên 12 bộ dữ liệu kiểm thử có gắn nhãn nguồn (120 câu hỏi) theo hai pha: pha truy xuất dùng các độ đo Precision@k, Recall@k, MRR; pha sinh ngôn ngữ dùng phương pháp LLM-as-a-judge với một mô hình ngôn ngữ thứ hai chấm điểm độc lập. Kết quả cho thấy câu trả lời đạt độ trung thực 4,25/5 và độ liên quan 4,36/5, chứng tỏ cơ chế RAG giúp cải thiện đáng kể độ tin cậy của thông tin sinh ra, đồng thời tạo ra một trải nghiệm học tập sinh động. Hệ thống hứa hẹn sẽ là một công cụ đắc lực hỗ trợ cả giáo viên và học

sinh trong quá trình chuyển đổi số ngành giáo dục.

Từ khóa: Trí tuệ nhân tạo, Mô hình ngôn ngữ lớn (LLM), Sinh văn bản tăng cường truy xuất (RAG), Trợ lý ảo, Sinh học trung học cơ sở, Qwen2.5, Vector Database.

Chương 1

TỔNG QUAN ĐỀ TÀI

1.1 Bối cảnh và tính cấp thiết

Trong bối cảnh chuyển đổi số trong giáo dục đang diễn ra mạnh mẽ, việc ứng dụng trí tuệ nhân tạo (AI) vào quá trình dạy và học ngày càng trở nên phổ biến và đóng vai trò quan trọng [56, 24]. Các hệ thống trợ lý ảo dựa trên mô hình ngôn ngữ lớn (Large Language Models – LLMs) đã thể hiện được khả năng vượt trội trong việc hiểu và sinh ngôn ngữ tự nhiên [6, 57], qua đó hỗ trợ học sinh tra cứu kiến thức, giải thích khái niệm và tương tác với nội dung học tập một cách linh hoạt [24]. Điều này đặc biệt hữu ích đối với các môn học khoa học tự nhiên như Sinh học, nơi học sinh cần hiểu nhiều khái niệm phức tạp liên quan đến cấu trúc sinh vật, hệ sinh thái, di truyền học và các quá trình sinh học.

Tuy nhiên, việc sử dụng trực tiếp các mô hình ngôn ngữ lớn trong giáo dục phổ thông vẫn tồn tại nhiều hạn chế đáng kể [24]. Thứ nhất, các mô hình này thường được huấn luyện trên khối lượng dữ liệu khổng lồ nhưng mang tính tổng quát, do đó có thể đưa ra thông tin không chính xác (hiện tượng ảo giác – hallucination) [20, 18] hoặc không phù hợp với chương trình học cụ thể của từng quốc gia hoặc cấp học. Thứ hai, kiến thức của mô hình bị "đóng băng" tại thời điểm huấn luyện và các hệ thống chatbot thông thường thiếu khả năng truy xuất tri thức một cách minh bạch từ các tài liệu chính thống như sách giáo khoa, tài liệu giảng dạy hoặc ngân hàng câu hỏi của giáo viên [26, 16]. Điều này làm giảm đáng kể độ tin cậy khi sử dụng AI như một nguồn tham khảo chuẩn mực trong môi trường giáo dục chính quy.

Gần đây, phương pháp sinh văn bản tăng cường truy xuất (Retrieval-Augmented Generation - RAG) [26] đã nổi lên như một hướng tiếp cận hiệu quả nhằm kết hợp khả năng sinh ngôn ngữ tự nhiên xuất sắc của LLM với khả năng truy xuất tri thức từ các nguồn dữ liệu chuyên biệt, đáng tin cậy [16]. Thay vì dựa hoàn toàn vào

"trí nhớ" (kiến thức đã được huấn luyện sẵn) của mô hình, cơ chế RAG cho phép hệ thống tìm kiếm thông tin liên quan từ một kho tri thức (knowledge base) trước khi tổng hợp và tạo ra câu trả lời [26, 17]. Cách tiếp cận này giúp cải thiện tính chính xác, khả năng giải thích (người dùng có thể biết thông tin được lấy từ đâu), và mức độ cập nhật của thông tin mà không cần phải huấn luyện lại toàn bộ mô hình ngôn ngữ với chi phí đắt đỏ [16].

Đặc thù của môn Sinh học ở cấp Trung học cơ sở (THCS) không chỉ chứa đựng lượng lý thuyết lớn mà còn đi kèm với rất nhiều hình ảnh minh họa quan trọng như cấu trúc tế bào, sơ đồ chuỗi thức ăn, các bộ phận của cơ thể sinh vật. Vì vậy, một hệ thống RAG không chỉ cần xử lý văn bản mà còn phải có khả năng hiểu và trích xuất hình ảnh (Multi-modal RAG), dựa trên các mô hình biểu diễn liên kết ngôn ngữ – thị giác như CLIP [41]. Từ những yêu cầu thực tiễn đó, việc thực hiện đề tài **"Xây dựng trợ lý ảo thông minh dựa trên RAG hỗ trợ dạy và học môn Sinh học tại các trường trung học cơ sở"** là một yêu cầu hết sức cấp thiết, không chỉ bắt kịp xu hướng công nghệ giáo dục (EdTech) mà còn trực tiếp giải quyết bài toán cung cấp học liệu cá nhân hóa, an toàn và chính xác cho học sinh và giáo viên.

1.2 Mục tiêu của đề tài

Đề tài hướng đến việc thiết kế, xây dựng và đánh giá một hệ thống trợ lý ảo thông minh dựa trên kỹ thuật Retrieval-Augmented Generation (RAG) nhằm hỗ trợ việc dạy và học môn Sinh học tại các trường trung học cơ sở. Các mục tiêu cụ thể của đề tài bao gồm:

- **Xây dựng kho tri thức chuyên biệt môn Sinh học:** Thu thập, xử lý và số hóa dữ liệu từ 12 cuốn sách giáo khoa Khoa học tự nhiên lớp 6, 7, 8, 9 của ba bộ sách (Kết nối tri thức với cuộc sống, Chân trời sáng tạo, Cánh Diều) [49, 50, 51, 52, 7, 8, 9, 10, 30, 31, 32, 33] được sử dụng chính thức trong chương trình giáo dục phổ thông mới, trong đó khai thác trọng tâm phần kiến thức Sinh học, tạo ra một cơ sở dữ liệu vector bao gồm cả văn bản và hình ảnh.
- **Thiết kế cơ chế truy xuất đa phương thức (Multi-modal Retrieval):** Phát triển luồng xử lý riêng biệt để nhúng (embed) văn bản và hình ảnh, đảm bảo khi học sinh đặt câu hỏi, hệ thống có thể truy xuất đồng thời đoạn văn bản giải thích và hình ảnh minh họa liên quan.
- **Tích hợp mô hình ngôn ngữ lớn (LLM):** Triển khai và tối ưu hóa mô hình LLM (như Qwen2.5) với cơ chế RAG để tạo ra câu trả lời chính xác, văn

phong phù hợp và dễ hiểu với trình độ học sinh cấp 2, hạn chế tối đa hiện tượng sinh ảo giác.

- **Phát triển giao diện người dùng (UI):** Xây dựng một ứng dụng web tương tác thân thiện, cho phép người dùng (học sinh, giáo viên) dễ dàng đặt câu hỏi, xem câu trả lời kèm theo hình ảnh trích dẫn và vị trí trang sách giáo khoa tương ứng.
- **Đánh giá hệ thống:** Xây dựng 12 bộ dữ liệu kiểm thử có gắn nhãn nguồn (mỗi cuốn sách một bộ) và thực nghiệm đánh giá hai pha: pha truy xuất đo bằng các độ đo định lượng khách quan (Precision@k, Recall@k, MRR) đối chiếu trực tiếp với trang nguồn; pha sinh ngôn ngữ đo bằng phương pháp LLM-as-a-judge với một mô hình ngôn ngữ thứ hai độc lập chấm điểm câu trả lời theo các tiêu chí tính đúng, độ trung thực và độ liên quan.

1.3 Đối tượng và phạm vi nghiên cứu

1.3.1 Đối tượng nghiên cứu

- Các công nghệ Xử lý ngôn ngữ tự nhiên (NLP) và Trí tuệ nhân tạo tạo sinh (Generative AI).
- Các mô hình ngôn ngữ lớn mã nguồn mở (Open-source LLMs).
- Kiến trúc hệ thống Retrieval-Augmented Generation (RAG) xử lý cả văn bản (Text) và hình ảnh (Image).
- Cơ sở dữ liệu Vector (Vector Database) và các mô hình nhúng (Embedding Models).

1.3.2 Phạm vi nghiên cứu

- **Về dữ liệu:** Nghiên cứu tập trung vào miền kiến thức **Sinh học** ở cấp Trung học cơ sở. Ở chương trình hiện hành, Sinh học là một phân môn nằm trong môn tích hợp Khoa học tự nhiên; do đó kho tri thức được xây dựng từ 12 cuốn sách giáo khoa Khoa học tự nhiên lớp 6, 7, 8, 9 của ba bộ sách (Kết nối tri thức với cuộc sống [49, 50, 51, 52], Chân trời sáng tạo [7, 8, 9, 10], Cánh Diều [30, 31, 32, 33]), với trọng tâm khai thác và đánh giá trên nội dung Sinh học.

- **Về mặt kỹ thuật:** Hệ thống được thiết kế dưới dạng ứng dụng Web, trong đó phần backend quản lý luồng RAG và LLM sử dụng ngôn ngữ Python cùng framework LangChain, cơ sở dữ liệu ChromaDB. Phần frontend cung cấp giao diện tương tác sử dụng framework Next.js.
- **Về đối tượng phục vụ:** Học sinh và giáo viên trung học cơ sở có nhu cầu tra cứu, tìm hiểu, giải đáp các thắc mắc xoay quanh nội dung môn Sinh học.

1.4 Cấu trúc của báo cáo

Báo cáo chuyên đề tốt nghiệp được cấu trúc thành 5 chương chính như sau:

- **Chương 1: Tổng quan đề tài.** Trình bày bối cảnh, tính cấp thiết, mục tiêu, đối tượng, phạm vi nghiên cứu của đề tài và bố cục tổng thể của quyển báo cáo.
- **Chương 2: Cơ sở lý thuyết.** Cung cấp các kiến thức nền tảng quan trọng phục vụ cho việc thực hiện đề tài, bao gồm các khái niệm về Xử lý ngôn ngữ tự nhiên, Mô hình ngôn ngữ lớn (LLM), nguyên lý hoạt động của kiến trúc Retrieval-Augmented Generation (RAG), hệ quản trị cơ sở dữ liệu Vector, cũng như phương pháp xử lý hình ảnh và văn bản.
- **Chương 3: Phương pháp thực hiện.** Mô tả chi tiết kiến trúc tổng thể của hệ thống trợ lý ảo, các công nghệ được lựa chọn. Trình bày quy trình trích xuất dữ liệu (ETL) văn bản và hình ảnh, cách thức xây dựng luồng RAG kết hợp đa phương thức và thiết kế giao diện ứng dụng.
- **Chương 4: Thực nghiệm, đánh giá và thảo luận.** Trình bày môi trường thực nghiệm, quy trình xây dựng 12 bộ dữ liệu kiểm thử có gắn nhãn nguồn, hệ thống độ đo hai pha (truy xuất và sinh ngôn ngữ), kết quả định lượng thực tế trên 120 câu hỏi kèm bảng biểu, biểu đồ minh họa, và thảo luận chuyên sâu về các phát hiện cùng hạn chế của hệ thống.
- **Chương 5: Kết luận.** Tóm tắt lại những kết quả quan trọng nhất mà đề tài đã đạt được, chỉ ra những hạn chế còn tồn tại và đề xuất các định hướng phát triển, cải tiến hệ thống trong tương lai.

Chương 2

CƠ SỞ LÝ THUYẾT

Chương này trình bày các khái niệm nền tảng tạo nên hệ thống trợ lý ảo thông minh. Nội dung bao gồm tổng quan về Xử lý ngôn ngữ tự nhiên, Mô hình ngôn ngữ lớn, kiến trúc Sinh văn bản tăng cường truy xuất (RAG) và các công nghệ lõi như Vector Database và Multi-modal Embedding.

2.1 Tổng quan về Xử lý ngôn ngữ tự nhiên và Trí tuệ nhân tạo tạo sinh

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) là một nhánh của Trí tuệ nhân tạo (AI) tập trung vào việc cho phép máy tính hiểu, diễn giải và thao tác với ngôn ngữ con người. Trong những năm gần đây, NLP đã chứng kiến sự chuyển mình mạnh mẽ từ các phương pháp dựa trên luật (rule-based) và học máy thống kê (statistical machine learning) sang các phương pháp dựa trên học sâu (Deep Learning) [4, 25]. Bước ngoặt đầu tiên đến từ việc biểu diễn từ dưới dạng véc-tơ phân tán (word embedding) như *word2vec* [35], theo sau là các kiến trúc mạng nơ-ron hồi quy và mô hình chuỗi-sang-chuỗi (sequence-to-sequence) kèm cơ chế chú ý (attention) cho dịch máy [45, 3].

Đặc biệt, sự ra đời của Trí tuệ nhân tạo tạo sinh (Generative AI) đã đánh dấu một bước ngoặt lớn. Thay vì chỉ phân loại hoặc nhận dạng mẫu trong dữ liệu (Discriminative AI), Generative AI có khả năng tạo ra nội dung mới, chưa từng tồn tại trước đó, như văn bản, hình ảnh, âm thanh hoặc mã nguồn, dựa trên sự phân phối xác suất học được từ tập dữ liệu khổng lồ [5]. Trong lĩnh vực văn bản, hạt nhân của Generative AI chính là các Mô hình ngôn ngữ lớn [57].

2.2 Mô hình ngôn ngữ lớn (Large Language Models - LLMs)

2.2.1 Kiến trúc Transformer

Được giới thiệu bởi Vaswani và cộng sự vào năm 2017 [47], kiến trúc Transformer đã trở thành nền tảng tiêu chuẩn cho hầu hết các LLM hiện đại. Điểm cốt lõi của Transformer là cơ chế tự chú ý (Self-Attention), cho phép mô hình đánh giá tầm quan trọng của các từ khác nhau trong cùng một câu khi xử lý từng từ một, bất kể khoảng cách giữa chúng.

Cơ chế này khắc phục được nhược điểm của mạng nơ-ron hồi quy (RNN) trong việc xử lý các chuỗi dài, đồng thời hỗ trợ tính toán song song, giúp quá trình huấn luyện trên phần cứng GPU trở nên cực kỳ hiệu quả. Trên nền tảng Transformer, hai dòng mô hình tiền huấn luyện tiêu biểu đã hình thành: dòng mã hóa hai chiều như BERT [13] chuyên cho các bài toán hiểu ngôn ngữ, và dòng giải mã tự hồi quy như GPT-3 [6] chuyên cho sinh văn bản. Nghiên cứu cũng chỉ ra rằng khi tăng quy mô tham số và dữ liệu, hiệu năng của mô hình tuân theo các quy luật tỷ lệ (scaling laws) [22] và làm xuất hiện những khả năng mới (emergent abilities) mà các mô hình nhỏ không có [54].

2.2.2 Họ mô hình Qwen

Qwen (Qwen2.5) là một trong những họ mô hình ngôn ngữ lớn mã nguồn mở tiên tiến hiện nay, được phát triển bởi Alibaba Cloud [40]. Xu hướng phát triển các LLM mã nguồn mở (như họ LLaMA [46]) cho phép cộng đồng nghiên cứu và triển khai mô hình mạnh mà không phụ thuộc hoàn toàn vào các API thương mại đóng. Phiên bản Qwen2.5-3B-Instruct được thiết kế tối ưu hóa cho khả năng tuân thủ chỉ thị (instruction following) – một năng lực đạt được nhờ tinh chỉnh theo chỉ thị và học tăng cường từ phản hồi của con người (RLHF) [38] – đồng thời giữ được kích thước tương đối nhỏ (khoảng 3 tỷ tham số), phù hợp để chạy trên các hệ thống có tài nguyên phần cứng hạn chế (ví dụ: Google Colab Pro hoặc GPU cá nhân tầm trung) mà vẫn đảm bảo được chất lượng sinh văn bản xuất sắc.

Mô hình này hỗ trợ đa ngôn ngữ, đặc biệt có khả năng xử lý tiếng Việt rất tốt, đáp ứng yêu cầu giao tiếp và giải thích ngữ nghĩa trong bài toán trợ lý ảo môn Sinh học. Việc xử lý hiệu quả tiếng Việt là một thách thức riêng đã được cộng đồng quan tâm thông qua các mô hình tiền huấn luyện chuyên biệt như PhoBERT [37].

2.3 Sinh văn bản tăng cường truy xuất (RAG)


2.3.1 Hạn chế của LLM truyền thống

Mặc dù LLM có khả năng sinh văn bản lưu loát, chúng gặp phải 3 vấn đề chính khi áp dụng vào thực tế [16]:

1. **Ảo giác (Hallucination):** Mô hình có thể sinh ra thông tin sai lệch một cách rất tự tin, không bám sát sự thật hoặc nguồn dẫn [20, 18].
2. **Kiến thức tĩnh:** LLM bị giới hạn kiến thức tại thời điểm huấn luyện, không thể cập nhật các thông tin mới nếu không được fine-tune (với chi phí cực cao) [26].
3. **Thiếu kiến thức miền (Domain-specific knowledge):** Mô hình không có quyền truy cập vào dữ liệu riêng của tổ chức, cá nhân, hoặc sách giáo khoa cụ thể [17].

2.3.2 Nguyên lý hoạt động của RAG

Retrieval-Augmented Generation (RAG) [26] là kiến trúc giải quyết các vấn đề trên bằng cách kết hợp cơ chế Truy xuất thông tin (Information Retrieval) với Sinh văn bản (Text Generation). Ý tưởng tăng cường mô hình ngôn ngữ bằng tri thức truy xuất từ kho dữ liệu ngoài đã được khẳng định qua nhiều công trình nền tảng như REALM [17] và Fusion-in-Decoder [19], và tiếp tục được hệ thống hóa, mở rộng trong các khảo sát gần đây [16] cũng như các biến thể có khả năng tự phản tỉnh như Self-RAG [2].



Hình 2.1: Sơ đồ nguyên lý hoạt động cơ bản của hệ thống RAG

Quy trình hoạt động của RAG bao gồm 2 pha chính:

- **Pha Indexing (Lập chỉ mục):** Dữ liệu gốc (PDF, Doc) được cắt nhỏ thành các đoạn (chunks). Các đoạn này được đưa qua mô hình Embedding để chuyển thành các vector số học và lưu trữ vào Vector Database.
- **Pha Query (Truy vấn):** Câu hỏi của người dùng được chuyển thành vector. Hệ thống tìm kiếm các vector trong Database có khoảng cách gần nhất (độ tương đồng cao nhất) với vector câu hỏi để lấy ra các đoạn văn bản chứa tri

thức liên quan (Context). Cơ chế truy xuất theo ngữ nghĩa này – thường gọi là truy xuất đoạn văn dày đặc (dense passage retrieval) [23] – giúp tìm được nội dung tương đồng về ý nghĩa ngay cả khi không trùng khớp từ khóa, khác với các phương pháp dựa trên thống kê từ khóa như BM25 [43]. Cuối cùng, LLM nhận đầu vào là Câu hỏi gốc + Context để sinh ra câu trả lời cuối cùng.

2.4 Nhúng (Embedding) và Cơ sở dữ liệu Vector

2.4.1 Khái niệm Embedding

Embedding là kỹ thuật chuyển đổi các thực thể (như từ, câu, đoạn văn, hoặc hình ảnh) thành các véc-tơ số học (vector n-chiều) liên tục [35]. Đặc tính quan trọng nhất của Embedding là khả năng bảo toàn ngữ nghĩa: các thực thể có ý nghĩa tương đồng sẽ nằm gần nhau trong không gian vector đa chiều. Đối với cấp độ câu và đoạn văn, kiến trúc Sentence-BERT [42] cho phép sinh ra các véc-tơ câu có thể so sánh trực tiếp bằng độ tương đồng cosine một cách hiệu quả. Ví dụ, câu "Tế bào là đơn vị cơ bản của sự sống" và "Mọi cơ thể sinh vật đều cấu tạo từ tế bào" sẽ có khoảng cách cosine rất nhỏ.

Dự án này sử dụng mô hình paraphrase-multilingual-MiniLM-L12-v2 (thuộc thư viện sentence-transformers [42]). Mô hình dựa trên kiến trúc MiniLM [53], một mô hình được chưng cất (distillation) từ Transformer lớn nhằm đạt sự cân bằng giữa kích thước gọn nhẹ và chất lượng biểu diễn ngữ nghĩa, phù hợp cho triển khai trên tài nguyên hạn chế và hỗ trợ tốt tiếng Việt.

2.4.2 Cơ sở dữ liệu Vector (ChromaDB)

Vector Database là hệ quản trị cơ sở dữ liệu chuyên biệt được thiết kế để lưu trữ và truy vấn các vector đa chiều một cách nhanh chóng thông qua cơ chế tìm kiếm tương đồng (Similarity Search) dựa trên các phép đo như Cosine Similarity, L2 Distance hay Inner Product. Để đạt tốc độ truy vấn cao trên hàng triệu véc-tơ, các hệ thống này áp dụng kỹ thuật tìm kiếm lân cận gần đúng (Approximate Nearest Neighbor – ANN), tiêu biểu là chỉ mục đồ thị HNSW [34] và các thư viện tìm kiếm tương đồng quy mô lớn như FAISS [21].

Trong hệ thống này, ChromaDB [12] được lựa chọn làm Vector Database nhờ đặc tính mã nguồn mở, hỗ trợ chạy trực tiếp trên máy cục bộ (local) mà không cần cài đặt server phức tạp, đồng thời tích hợp chặt chẽ với framework LangChain [11], giúp dễ dàng thao tác lưu trữ và truy xuất các đoạn kiến thức (chunks) từ sách giáo khoa Sinh học.

2.5 Xử lý Đa phương thức (Multi-modal) trong RAG

Sách giáo khoa môn Sinh học chứa rất nhiều hình ảnh (hình vẽ giải phẫu, sơ đồ quá trình quang hợp, v.v.). Một hệ thống RAG văn bản thuần túy sẽ bỏ sót những lượng thông tin khổng lồ này. Do đó, kỹ thuật Multi-modal RAG được áp dụng, dựa trên những tiến bộ của thị giác máy tính khi đưa kiến trúc Transformer vào xử lý ảnh (Vision Transformer) [14] và các mô hình tiền huấn luyện liên kết ngôn ngữ – thị giác [41, 27]. Bản thân bài toán hỏi đáp dựa trên hình ảnh (Visual Question Answering) [1] cũng là một hướng nghiên cứu nền tảng cho việc kết hợp văn bản và hình ảnh.

2.5.1 Mô hình trích xuất và gán nhãn ảnh

Hệ thống sử dụng các mô hình thị giác máy tính (Computer Vision) kết hợp:

- **OwlViT** (google/owlvit-base-patch32) [36]: Mô hình phát hiện vật thể (Object Detection) dựa trên Zero-shot text-conditioned, được dùng để xác định vị trí hộp bao (bounding box) của các hình ảnh, biểu đồ nằm rải rác trong các trang sách PDF.
- **CLIP** (openai/clip-vit-base-patch16) [41]: Sinh vector embedding cho hình ảnh, cho phép so sánh độ tương đồng giữa câu hỏi (text) và hình ảnh (image) trong cùng một không gian vector.
- **Vintern-1B** (5CD-AI/Vintern-1B-v2): Một mô hình VQA (Visual Question Answering) chuyên biệt hỗ trợ tiếng Việt, dùng để tự động sinh ra mô tả (caption) cho từng hình ảnh được cắt ra. Việc có caption văn bản cho ảnh giúp cải thiện đáng kể độ chính xác của quá trình truy xuất sau này.

Kết hợp các công nghệ này, kiến trúc Multi-modal RAG của hệ thống đảm bảo cả luồng tri thức văn bản và hình ảnh được lưu trữ và truy xuất đồng bộ, cung cấp ngữ cảnh đầy đủ nhất cho mô hình LLM sinh câu trả lời.

Chương 3

PHƯƠNG PHÁP THỰC HIỆN VÀ KIẾN TRÚC HỆ THỐNG

Chương này đi sâu vào chi tiết các bước thiết kế và triển khai hệ thống trợ lý ảo môn Sinh học. Nó bắt đầu từ việc trình bày kiến trúc tổng thể, sau đó là các kỹ thuật xử lý dữ liệu (ETL pipeline), luồng truy xuất tạo câu trả lời (RAG pipeline), và kết thúc bằng việc thiết kế giao diện tương tác người dùng (Frontend).


3.1 Kiến trúc tổng thể hệ thống

Hệ thống trợ lý ảo được thiết kế theo mô hình Client-Server hiện đại, bao gồm hai thành phần chính: Backend (xử lý logic RAG, tương tác với LLM và Database) và Frontend (Giao diện Web cho người dùng).

Backend được xây dựng dựa trên ngôn ngữ Python, sử dụng Flask làm API Server và LangChain [11] làm framework cốt lõi để dàn xếp (orchestrate) các tác vụ truy xuất và sinh văn bản. Frontend được phát triển bằng Next.js, cung cấp trải nghiệm web mượt mà (SPA - Single Page Application).

3.2 Quy trình thu thập và xử lý dữ liệu (ETL Pipeline)

Quy trình Extract, Transform, Load (ETL) là trái tim của việc xây dựng Kho tri thức (Knowledge Base) cho trợ lý ảo. Đặc thù của nội dung Sinh học trong sách giáo khoa là sự đan xen giữa lý thuyết phức tạp và hình ảnh trực quan (sơ đồ tế bào, quá trình quang hợp, cấu tạo cơ thể sinh vật...), do đó quy trình ETL được chia làm 2 luồng độc lập để xử lý lượng lớn dữ liệu từ 12 cuốn sách giáo khoa nói trên [49, 50, 51, 52, 7, 8, 9, 10, 30, 31, 32, 33]:



Hình 3.1: Sơ đồ kiến trúc tổng thể của hệ thống Trợ lý ảo RAG

3.2.1 Xử lý Dữ liệu Văn bản (Text ETL)

Quy trình Text ETL chịu trách nhiệm đọc các file PDF sách giáo khoa, trích xuất chữ và lưu vào ChromaDB.

1. **Đọc và trích xuất chữ (OCR):** Đối với các trang sách dạng ảnh hoặc có định dạng phức tạp, hệ thống sử dụng thư viện Tesseract OCR [44] và PDF2Image (thông qua Poppler) để chuyển đổi hình ảnh thành văn bản tiếng Việt (tesseract-ocr-vie).
2. **Phân mảnh văn bản (Chunking):** Không thể đưa toàn bộ quyển sách vào LLM vì giới hạn cửa sổ ngữ cảnh (context window). Văn bản được chia nhỏ bằng Recursive-Character-TextSplitter của LangChain với `chunk_size = 400` ký tự và `chunk_overlap = 120` ký tự. Kích thước 400 được chọn nhằm đảm bảo mỗi đoạn văn chứa đủ một ý nghĩa sinh học trọn vẹn, còn khoảng chồng lấn (overlap) 120 ký tự giúp giữ được ngữ cảnh liên kết giữa các đoạn liền kề.
3. **Nhúng và lưu trữ (Embedding & Indexing):** Các đoạn text được đưa qua mô hình `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` để tạo vector 384 chiều và lưu vào collection `biology_text` trong ChromaDB.

3.2.2 Xử lý Dữ liệu Hình ảnh (Image ETL)

Học sinh khi hỏi về Sinh học thường cần xem hình vẽ. Luồng Image ETL hoạt động như sau:

1. **Cắt ảnh tự động:** Sử dụng mô hình `google/owlvit-base-patch32` (với ngưỡng `confidence threshold 0.1`) để quét từng trang sách, nhận diện các khu vực có chứa hình vẽ, biểu đồ và tự động cắt (crop) chúng ra khỏi trang.
2. **Sinh mô tả tự động (Image Captioning):** Hình ảnh cắt ra được đưa qua mô hình `5CD-AI/Vintern-1B-v2` để tự động sinh ra đoạn văn bản mô tả tiếng Việt chi tiết về nội dung bức ảnh (ví dụ: "Sơ đồ quang hợp ở thực vật").
3. **Chỉ mục đa phương thức:** Vector của hình ảnh được tạo ra bằng `openai/clip-vit-base-patch16`, lưu cùng với metadata (bao gồm caption tiếng Việt, số trang, tọa độ) vào collection `biology_images`.

Để tăng chất lượng tìm kiếm, hệ thống cũng cung cấp các script (ví dụ: `main.py -export-image-review`) cho phép xuất dữ liệu ảnh ra file JSON để chuyên gia (giáo viên) rà soát, chỉnh sửa thủ công caption (human-in-the-loop) rồi apply ngược lại vào Database.

3.3 Luồng truy xuất và sinh văn bản (RAG Pipeline)

Khi người dùng (học sinh) nhập câu hỏi trên giao diện, Backend tiếp nhận yêu cầu và xử lý theo quy trình RAG đa phương thức:

1. **Truy xuất kép (Dual Retrieval):** Câu hỏi được embed để tìm kiếm đồng thời trong collection Text (RETRIEVER_K = 3 đoạn text gần nhất) và collection Image (IMAGE_RETRIEVER_K = 5 hình ảnh liên quan nhất dựa trên caption và CLIP vector).
2. **Tiền xử lý prompt:** Text context được ghép nối với các caption của hình ảnh tìm được. Một Prompt template chuyên biệt cho trợ lý giáo dục được sử dụng để ép LLM đóng vai trò một giáo viên Sinh học nhiệt tình, chỉ trả lời dựa trên ngữ cảnh được cung cấp.
3. **Sinh văn bản (Generation):** Mô hình Qwen2.5 [40] (sử dụng thư viện transformers [55] và HuggingFace-Pipeline) nhận prompt và sinh ra câu trả lời cuối cùng. Thông số temperature = 0.1 được thiết lập thấp để LLM đưa ra câu trả lời chính xác, tránh việc "sáng tạo" quá mức làm sai lệch kiến thức khoa học.


3.3.1 Định tuyến theo ý định truy vấn (Query Intent Routing)

Không phải câu hỏi nào cũng cần cả văn bản lẫn hình ảnh. Trước khi truy xuất, hệ thống phân tích ý định của câu hỏi: nếu câu hỏi mang tính *chỉ-hình-ảnh* (ví dụ chứa các cụm "cho tôi xem hình", "ảnh minh họa", "sơ đồ"), hệ thống ưu tiên luồng tìm ảnh; ngược lại, luồng văn bản giữ vai trò chính và hình ảnh chỉ đóng vai trò hỗ trợ minh họa. Cơ chế định tuyến này (cài đặt trong module query_intent) giúp tránh đưa nhiều hình ảnh vào những câu hỏi lý thuyết thuần túy.

3.3.2 Truy xuất lai và cơ chế lọc liên quan (Hybrid Retrieval & Relevance Gate)

Một bộ truy xuất top- k thông thường luôn trả về đúng k đoạn bất kể chúng có thực sự liên quan hay không, khiến các đoạn lạc chủ đề "lọt" vào ngữ cảnh và làm mô hình sinh ra câu trả lời ghép nối sai. Để khắc phục, hệ thống sử dụng một bộ truy xuất **có cổng lọc liên quan** (RelevanceGatedRetriever) hoạt động theo nguyên tắc khoảng cách tương đối:

1. Lấy rộng RETRIEVER_FETCH_K = 8 đoạn ứng viên cùng khoảng cách (distance) của chúng.



Hình 3.2: Luồng xử lý truy vấn RAG Đa phương thức trong Backend

2. Gọi $d_{\min}$ là khoảng cách của đoạn gần nhất. Chỉ giữ lại các đoạn có khoảng cách $d \leq d_{\min}(1+\text{margin})$ với $\text{margin} = 0.3$, và cắt tối đa `RETRIEVER_MAX_K` = 4 đoạn.

Nhờ cổng lọc này, những đoạn nằm xa cụm chủ đề tốt nhất sẽ bị loại, giảm hẳn hiện tượng "chảy máu ngữ cảnh" (context bleeding) giữa các trang không liên quan. Toàn bộ kết quả văn bản và hình ảnh sau đó được hợp nhất trong một bộ truy xuất lai (HybridRetriever) trước khi dựng prompt. Như sẽ phân tích ở Chương 4, chính cấu hình cắt-k chặt chẽ này vừa là ưu điểm (giảm nhiễu) vừa là điểm đánh đổi (làm giảm recall), và là một định hướng tinh chỉnh quan trọng.

3.4 Thiết kế giao diện người dùng (Frontend)


Giao diện ứng dụng đóng vai trò quan trọng trong việc thu hút học sinh sử dụng. Frontend của dự án được triển khai bằng **Next.js 14** và **React 19**.

Về mặt thẩm mỹ và tương tác:


- **Tailwind CSS:** Được sử dụng để xây dựng thiết kế theo chuẩn UI/UX hiện đại, màu sắc thân thiện với lứa tuổi học sinh, giao diện tương thích tốt trên cả máy tính và thiết bị di động (Responsive).
- **Framer Motion:** Tích hợp nhằm tạo ra các hiệu ứng hoạt hình (animations) mượt mà khi gửi tin nhắn, hiển thị kết quả truy xuất, tạo cảm giác như học sinh đang trò chuyện trực tiếp với một "gia sư AI" thực thụ.
- **Hiển thị hình ảnh:** Giao diện chat không chỉ in ra chữ mà còn hiển thị trực tiếp các hình ảnh minh họa (cùng trang sách gốc) được Backend trả về trong payload của API, giúp bài giảng Sinh học trở nên sinh động và dễ hình dung hơn bao giờ hết.

3.4.1 Một số giao diện tiêu biểu


Hình 3.3 minh họa các màn hình chính trong luồng tương tác của người dùng: từ đăng nhập, đặt câu hỏi, đến khung trò chuyện và câu trả lời kèm hình ảnh minh họa. Hình 3.4 thể hiện tính năng đặc trưng của hệ thống đa phương thức — khi học sinh nhấp vào một hình, giao diện hiển thị chi tiết hình minh họa Sinh học cùng trích dẫn trang sách gốc.




(a) Màn hình đăng nhập



(b) Đặt câu hỏi




(c) Khung trò chuyện



(d) Câu trả lời kèm hình minh họa

Hình 3.3: Các màn hình chính của giao diện trợ lý ảo Sinh học.



Hình 3.4: Chi tiết hình ảnh minh họa Sinh học kèm trích dẫn trang sách gốc do hệ thống trả về.

Chương 4

THỰC NGHIỆM, ĐÁNH GIÁ VÀ THẢO LUẬN

Chương này trình bày toàn bộ quá trình thực nghiệm và đánh giá định lượng hệ thống trợ lý ảo. Nội dung bao gồm: thiết lập môi trường và bộ công cụ thực nghiệm; quy trình xây dựng 12 bộ dữ liệu kiểm thử (mỗi cuốn sách giáo khoa một bộ) có gắn nhãn nguồn (ground truth) để đo lường khách quan; hệ thống độ đo đánh giá tách thành hai pha (truy xuất và sinh ngôn ngữ); kết quả thực nghiệm thực tế trên 120 câu hỏi cùng các bảng biểu, biểu đồ minh họa; và cuối cùng là phần thảo luận chuyên sâu về ưu điểm, hạn chế cũng như các phát hiện quan trọng rút ra từ số liệu.

4.1 Môi trường và công cụ thực nghiệm

Quá trình tiền xử lý dữ liệu (OCR, phát hiện và cắt ảnh, sinh chú thích) cùng với suy luận của mô hình ngôn ngữ lớn đòi hỏi tài nguyên tính toán lớn, đặc biệt là bộ nhớ GPU. Hệ thống được phát triển và thực nghiệm trên nền tảng điện toán đám mây với cấu hình trình bày trong Bảng 4.1.

Bảng 4.1: Cấu hình môi trường và ngăn xếp công nghệ thực nghiệm

Thành phần	Chi tiết
Nền tảng tính toán	Google Colab Pro (High-RAM $\approx$ 50GB)
GPU	NVIDIA A100 40GB VRAM
Ngôn ngữ	Python 3.10
Framework cốt lõi	LangChain 0.2+, Transformers 4.40+, PyTorch 2.0+
Cơ sở dữ liệu vector	ChromaDB 0.5+
Mô hình sinh (LLM)	Qwen2.5-3B-Instruct (float16)
Mô hình nhúng văn bản	paraphrase-multilingual-MiniLM-L12-v2 (384 chiều)
Mô hình thị giác	CLIP-ViT-B/16, OwlViT-B/32, Vintern-1B-v2
LLM giám khảo (judge)	MiMo-v2.5-pro (gọi qua API tương thích OpenAI)

Việc sử dụng GPU A100 40GB VRAM cho phép nạp đồng thời mô hình sinh Qwen2.5-3B-Instruct (khoảng 6–8GB VRAM ở định dạng float16) cùng các mô hình thị giác (CLIP, OwlViT, Vintern-1B), nhờ đó tốc độ phản hồi của trợ lý ảo đạt mức gần thời gian thực. Mô hình giám khảo được tách riêng và truy cập qua API tương thích chuẩn OpenAI, bảo đảm *tính độc lập* giữa mô hình bị đánh giá (Qwen2.5) và mô hình chấm điểm — một nguyên tắc quan trọng của phương pháp LLM-as-a-judge nhằm tránh thiên kiến tự đánh giá (self-enhancement bias) [58].

4.2 Bộ dữ liệu tri thức đã số hóa và lập chỉ mục

Trước khi đánh giá, kho tri thức (knowledge base) của hệ thống được xây dựng từ **12 bộ sách giáo khoa Khoa học tự nhiên** lớp 6, 7, 8, 9 của ba bộ sách (Cánh Diều, Chân trời sáng tạo, Kết nối tri thức với cuộc sống), toàn bộ ở **định dạng PDF** với tổng cộng **2.319 trang**. Quy trình ETL hai luồng (Mục 3) xử lý song song văn bản và hình ảnh; kết quả lập chỉ mục được lưu trong ba collection của ChromaDB và tóm tắt theo từng bộ sách trong Bảng 4.2.

Luồng văn bản. Sau khi trích xuất chữ (OCR) và phân mảnh (chunk 400 ký tự, phần chồng lấn 120 ký tự), toàn bộ corpus sinh ra **13.754 đoạn văn bản (chunk)**. Mỗi đoạn được nhúng bằng mô hình paraphrase-multilingual-MiniLM-L12-v2 thành một **vector 384 chiều**, tạo nên **13.754 vector văn bản** lưu trong collection `biology_text`.

Luồng hình ảnh. Mô hình OwlViT phát hiện và cắt các vùng hình minh họa trên từng trang; sau các bước lọc độ liên quan bằng CLIP, khử trùng lặp và rà soát thủ công, hệ thống giữ lại **2.408 hình ảnh** đặc thù môn Sinh học (gồm 1.166 hình đơn, 504 hình con, 401 khung hoạt động, 176 hình ghép, 130 khung thông

tin và 31 nhóm dụng cụ thí nghiệm). Trong đó, **2.384 hình** đã được mô hình Vintern-1B sinh chú thích (caption) tiếng Việt tự động. Mỗi hình được nhúng bằng clip-vit-base-patch16 thành một **vector 512 chiều**, tạo nên **2.408 vector hình ảnh** trong collection `biology_images`, đi kèm **2.408 bản ghi metadata** (caption, số trang, tọa độ hộp bao) trong collection `biology_image_metadata`.

Bảng 4.2: Thống kê bộ dữ liệu tri thức đã số hóa và lập chỉ mục theo từng bộ sách

Khối	Bộ sách	Số trang (PDF)	Chunk/vector văn bản	Vector hình ảnh
Lớp 6	KHTN 6 Cánh Diều	182	863	379
	KHTN 6 Chân trời sáng tạo	207	940	296
	KHTN 6 Kết nối tri thức	199	912	106
Lớp 7	KHTN 7 Cánh Diều	174	1.042	296
	KHTN 7 Chân trời sáng tạo	187	1.061	198
	KHTN 7 Kết nối tri thức	182	924	53
Lớp 8	KHTN 8 Cánh Diều	155	811	231
	KHTN 8 Chân trời sáng tạo	232	1.407	225
	KHTN 8 Kết nối tri thức	246	1.660	20
Lớp 9	KHTN 9 Cánh Diều	220	1.392	408
	KHTN 9 Chân trời sáng tạo	219	1.364	168
	KHTN 9 Kết nối tri thức	116	1.378	28
Tổng cộng		2.319	13.754	2.408

Như vậy, kho tri thức cuối cùng gồm **16.162 vector** (13.754 vector văn bản 384 chiều và 2.408 vector hình ảnh 512 chiều) được lập chỉ mục trên ChromaDB, sẵn sàng phục vụ truy xuất đa phương thức. Có thể thấy mật độ hình ảnh chênh lệch đáng kể giữa các bộ sách (ví dụ KHTN 9 Cánh Diều có 408 hình trong khi KHTN 8 Kết nối tri thức chỉ có 20 hình được giữ lại), phản ánh khác biệt về bố cục trình bày và mức độ thân thiện với việc tự động phát hiện hình ảnh của từng bộ sách.

4.3 Xây dựng bộ dữ liệu kiểm thử (Testsets)

Khác với cách đánh giá chỉ dựa trên cảm tính hoặc một vài câu hỏi rời rạc, luận văn xây dựng một quy trình sinh dữ liệu kiểm thử **có gắn nhãn nguồn xác định**. Đây là điều kiện then chốt để có thể tính các độ đo truy xuất (Precision, Recall, MRR) một cách *khách quan và lặp lại được*, thay vì phụ thuộc hoàn toàn vào đánh giá ngữ nghĩa của một mô hình khác.

4.3.1 Nguyên lý gắn nhãn nguồn (ground truth)

Mỗi câu hỏi kiểm thử được sinh ra từ **một trang cụ thể** của một cuốn sách giáo khoa cụ thể. Do đó, với mỗi câu hỏi, hệ thống biết chắc *tài liệu vàng* (gold document) là cặp (tên_sách, số_trang). Khi chạy thử nghiệm truy xuất, ta đối chiếu phần *metadata* (source, page) của các đoạn văn bản (chunk) mà hệ thống trả về với tài liệu vàng này để xác định đoạn nào là *đúng*. Cơ chế đối chiếu khả thi nhờ trong quá trình ETL (Chương 3), mỗi chunk lưu trong collection `biology_text` đều mang metadata gồm tên file PDF gốc và số trang tương ứng.

4.3.2 Quy trình sinh dữ liệu tự động

Quy trình sinh testset được tự động hóa hoàn toàn và mô tả trong Thuật toán 1. Với mỗi cuốn sách, hệ thống chọn ngẫu nhiên (với hạt giống cố định `seed=42` để tái lập) một số trang nội dung, bỏ qua các trang đầu (bìa, mục lục, lời nói đầu) và các trang quá ít chữ. Nội dung trang được OCR bằng Tesseract, sau đó đưa cho mô hình LLM đặt một câu hỏi kèm đáp án chuẩn (ground truth) **chỉ dựa trên nội dung trang đó**. Kết quả được lưu kèm cặp (`source_book`, `source_page`).

Algorithm 1: Sinh bộ kiểm thử có gắn nhãn nguồn cho một cuốn sách

Input: Thư mục ảnh trang của sách B ; số câu cần sinh N ; ngưỡng chữ tối thiểu L_{min}

Output: Danh sách bộ (question, ground_truth, source_book, source_page)

```

1 Lấy danh sách trang, bỏ 10 trang đầu (bìa/mục lục);
2 Xáo trộn danh sách trang với hạt giống cố định;
3  $rows \leftarrow \emptyset$ ;
4 foreach trang  $p$  trong danh sách ứng viên do
5   if  $|rows| \geq N$  then
6     | dừng
7   end
8    $text \leftarrow \text{OCR}(p)$ ;
9   if  $\text{độ\_dài}(text) < L_{min}$  then
10    | bỏ qua
11  end
12   $(q, gt, ok) \leftarrow \text{LLM\_sinh\_câu\_hỏi}(text)$ ;
13  if  $ok$  then
14    | Thêm  $(q, gt, B, p)$  vào  $rows$ ;
15  end
16 end
17 return  $rows$ ;

```

Tổng cộng, hệ thống đã sinh được **120 câu hỏi** phân bố đều trên 12 cuốn sách (10 câu mỗi cuốn) như trình bày trong Bảng 4.3. Các câu hỏi tập trung vào nội dung **Sinh học** của chương trình (cấu tạo và hoạt động của tế bào, quang hợp, hô hấp, sinh vật và phân loại, di truyền, cơ thể người...) và trải đều ba cấp độ: trích xuất trực tiếp, suy luận liên kết, và tổng hợp đa ngữ cảnh.

Bảng 4.3: Phân bố 12 bộ dữ liệu kiểm thử theo cuốn sách

Khối	Bộ sách	Số câu hỏi
Lớp 6	Cánh diều, Chân trời sáng tạo, Kết nối tri thức	3×10
Lớp 7	Cánh diều, Chân trời sáng tạo, Kết nối tri thức	3×10
Lớp 8	Cánh diều, Chân trời sáng tạo, Kết nối tri thức	3×10
Lớp 9	Cánh diều, Chân trời sáng tạo, Kết nối tri thức	3×10
Tổng cộng		120

Bảng 4.4 minh họa một số câu hỏi tiêu biểu cùng đáp án chuẩn và trang nguồn

được gắn nhãn.

Bảng 4.4: Một số câu hỏi kiểm thử tiêu biểu kèm nhãn nguồn

Câu hỏi (Sinh học)	Đáp án chuẩn (ground truth)	Nguồn
Oxygen cần cho quá trình nào và carbon dioxide cần cho quá trình nào ở sinh vật?	Oxygen cần cho sự hô hấp; carbon dioxide cần cho sự quang hợp.	6 CD, tr.41
Trong các nguyên sinh vật được quan sát, nguyên sinh vật nào gây ra bệnh sốt rét?	Trùng sốt rét.	6 CTST, tr.120
Khi quan sát tế bào dưới kính hiển vi, vật kính nào được sử dụng đầu tiên?	Vật kính 10×.	6 KNTT, tr.75
Giá trị pH của máu ở người khỏe mạnh nằm trong khoảng nào?	Từ 7,35 đến 7,45.	8 CTST, tr.56

4.4 Phương pháp và độ đo đánh giá

Do đầu ra của hệ thống là ngôn ngữ tự nhiên, việc dùng các thang đo so khớp từ khóa truyền thống như BLEU [39] hay ROUGE [28] là không đủ, vì một câu trả lời đúng có thể được diễn đạt bằng nhiều cách khác nhau về mặt từ ngữ. Luận văn áp dụng phương pháp đánh giá **hai pha**: (i) pha truy xuất được đo bằng các độ đo truy hồi thông tin (IR) *xác định* dựa trên nhãn nguồn; (ii) pha sinh ngôn ngữ được đo bằng mô hình **LLM-as-a-judge** [58, 29] với một mô hình LLM thứ hai độc lập (MiMo-v2.5-pro). Cách tiếp cận dùng LLM để chấm điểm chất lượng câu trả lời của hệ thống RAG cũng phù hợp với các khung đánh giá chuyên biệt cho RAG gần đây như RAGAS [15]. Toàn bộ luồng đánh giá tự động được mô tả trong Hình 4.1 (về mặt khái niệm) và Thuật toán 2.

4.4.1 Đánh giá pha truy xuất (Retrieval Evaluation)

Gọi $R_k = (d_1, d_2, \dots, d_m)$ là danh sách $m \leq k$ đoạn văn bản hệ thống truy xuất được cho một câu hỏi, sắp theo thứ hạng. Hàm chỉ thị liên quan ở mức trang (page-level) được định nghĩa là:

$$\text{rel}(d) = \begin{cases} 1 & \text{nếu } \text{source}(d) = B^* \wedge |\text{page}(d) - p^*| \leq 1 \\ 0 & \text{ngược lại} \end{cases} \quad (4.1)$$

trong đó (B^*, p^*) là sách và trang nguồn của câu hỏi. Dung sai ± 1 trang được dùng vì một đoạn văn bản có thể tràn qua ranh giới trang do cơ chế chunking. Ba độ đo chính được tính như sau:

- **Precision@k** — tỷ lệ đoạn truy xuất là đúng trang nguồn:

$$\text{Precision@k} = \frac{1}{|R_k|} \sum_{d \in R_k} \text{rel}(d). \quad (4.2)$$

- **Recall@k (hit@k)** — do mỗi câu hỏi chỉ có một trang vàng, recall là việc trang đó có xuất hiện trong top- k hay không:

$$\text{Recall@k} = 1[\exists d \in R_k : \text{rel}(d) = 1]. \quad (4.3)$$

- **MRR (Mean Reciprocal Rank — điểm rank)** [48] — nghịch đảo thứ hạng của đoạn đúng đầu tiên, lấy trung bình trên N câu hỏi:

$$\text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i}, \quad (4.4)$$

với rank_i là vị trí đoạn đúng đầu tiên của câu hỏi thứ i (bằng ∞ , tức đóng góp 0, nếu không có đoạn đúng nào).

Ngoài mức page-level (ngghiêm ngặt), luận văn còn tính các độ đo tương ứng ở mức **book-level** (chỉ cần đúng sách) nhằm định lượng hiện tượng nhiễu chéo giữa 12 cuốn sách vốn được lưu chung trong một collection. Bên cạnh đó, để tách bạch khả năng tìm thấy của mô hình nhúng với tổn thất do khâu lọc/cắt- k ở cấu hình production, hệ thống còn đo **Recall@k thô** (raw top- k , bỏ qua bộ lọc liên quan) tại các mức $k \in \{3, 5, 10\}$; giá trị Recall@10 đóng vai trò *trần recall* (ngưỡng tốt nhất có thể đạt nếu nói rộng số đoạn lấy ra).

4.4.2 Đánh giá pha sinh ngôn ngữ (LLM-as-a-judge)

Câu trả lời do Qwen2.5 sinh ra được một mô hình LLM thứ hai (MiMo-v2.5-pro) chấm điểm độc lập. Mô hình giám khảo nhận đầu vào gồm câu hỏi, đáp án chuẩn, ngữ cảnh truy xuất và câu trả lời cần chấm, rồi trả về điểm theo ba tiêu chí trên thang 1–5:

- **Tính đúng (Correctness)**: câu trả lời có chính xác so với đáp án chuẩn hay không.
- **Độ trung thực (Faithfulness)**: câu trả lời có bám sát ngữ cảnh được cung cấp, không bịa đặt (hallucination) hay không.
- **Độ liên quan (Relevancy)**: câu trả lời có đi đúng trọng tâm câu hỏi hay không.

4.4.3 Điểm tổng hợp và xếp hạng

Để xếp hạng 12 cuốn sách, mỗi cuốn được quy về một *điểm tổng thể* cân bằng giữa chất lượng truy xuất và chất lượng câu trả lời:

$$\text{retrieval_score} = \text{mean}(\text{Recall}@k_{\text{page}}, \text{MRR}_{\text{page}}, \text{Precision}@k_{\text{page}}), \quad (4.5)$$

$$\text{answer_score} = \frac{1}{5} \text{mean}(\text{Correctness}, \text{Faithfulness}, \text{Relevancy}), \quad (4.6)$$

$$\text{overall} = \frac{1}{2}(\text{retrieval_score} + \text{answer_score}). \quad (4.7)$$


Algorithm 2: Quy trình đánh giá tự động cho một bộ kiểm thử

Input: Bộ kiểm thử của sách B ; mô hình giám khảo J

Output: Các độ đo trung bình của sách B

```

1 foreach câu hỏi  $q$  kèm nhãn  $(B^*, p^*)$  do
2    $R \leftarrow \text{HybridRetriever}(q)$ ;           // truy xuất như API thật
3   Tính  $\text{Precision}@k$ ,  $\text{Recall}@k$ ,  $\text{MRR}$  từ metadata của  $R$  và  $(B^*, p^*)$ ;
4   Tính  $\text{Recall}@ \{3,5,10\}$  thô bằng tìm kiếm top-k bỏ qua bộ lọc;
5    $\text{ctx} \leftarrow$  ghép nội dung các đoạn trong  $R$ ;
6    $\text{ans} \leftarrow \text{Qwen2.5}(\text{prompt}(\text{ctx}, q))$ ;
7    $(\text{corr}, \text{faith}, \text{rel}) \leftarrow J(q, \text{gt}, \text{ctx}, \text{ans})$ ;           // LLM thứ hai chấm
8   Lưu lại toàn bộ chỉ số của câu hỏi;
9 end
10 return trung bình các chỉ số trên toàn bộ câu hỏi của  $B$ ;
```



Hình 4.1: Luồng đánh giá tự động: câu hỏi đi qua đúng pipeline RAG thật (truy xuất → Qwen2.5 sinh câu trả lời), sau đó được đo bằng độ đo IR và mô hình giám khảo thứ hai.

4.5 Kết quả thực nghiệm

Phần này trình bày kết quả định lượng thu được khi chạy toàn bộ 120 câu hỏi qua hệ thống. Các số liệu trung bình tổng quát được tóm tắt trong Bảng 4.5.

Bảng 4.5: Các độ đo trung bình trên toàn bộ 120 câu hỏi (12 bộ sách)


Độ đo	Giá trị trung bình
Recall@k (production, page-level)	0.63
MRR (page-level)	0.51
Precision@k (page-level)	0.38
Recall@3 (thô)	0.66
Recall@5 (thô)	0.77
Recall@10 (thô — trần recall)	0.84
Tính đúng (Correctness, /5)	3.76
Độ trung thực (Faithfulness, /5)	4.25
Độ liên quan (Relevancy, /5)	4.36
Điểm tổng thể (overall)	0.67

4.5.1 Xếp hạng tổng thể 12 bộ sách

Bảng 4.6 và Hình 4.2 trình bày bảng xếp hạng tổng thể của 12 cuốn sách theo điểm overall. Cuốn *KHTN 9 Cánh diều* đạt điểm cao nhất (0.783) nhờ cân bằng tốt giữa truy xuất và chất lượng trả lời, trong khi *KHTN 6 Kết nối tri thức* xếp cuối (0.524) chủ yếu do recall truy xuất thấp.


Bảng 4.6: Bảng xếp hạng tổng thể 12 bộ sách (judge: MiMo-v2.5-pro)

Hạng	Bộ sách	Overall	Recall@k	MRR	Precision	Correct/5	Faithful/5	Relevancy/5
1	KHTN 9 CD	0.783	0.80	0.67	0.53	4.20	4.70	4.60
2	KHTN 7 CD	0.734	0.80	0.63	0.43	3.80	4.40	4.50
3	KHTN 6 CTST	0.716	0.70	0.65	0.38	3.80	4.30	4.70
4	KHTN 8 CTST	0.714	0.80	0.68	0.50	3.40	3.80	4.30
5	KHTN 8 KNTT	0.710	0.60	0.50	0.50	4.00	4.90	4.40
6	KHTN 8 CD	0.692	0.60	0.53	0.40	4.00	4.60	4.50
7	KHTN 9 CTST	0.677	0.70	0.55	0.33	4.00	4.10	4.30
8	KHTN 7 KNTT	0.672	0.60	0.43	0.30	4.40	4.40	4.70
9	KHTN 9 KNTT	0.671	0.60	0.53	0.43	3.80	4.10	4.40
10	KHTN 7 CTST	0.577	0.60	0.42	0.27	2.90	4.30	3.70
11	KHTN 6 CD	0.528	0.50	0.28	0.27	3.30	3.40	3.90
12	KHTN 6 KNTT	0.524	0.30	0.25	0.23	3.50	4.00	4.30



Hình 4.2: Xếp hạng tổng thể 12 bộ sách theo điểm overall.

Hình 4.3 phân tách điểm tổng thể thành hai thành phần. Có thể thấy điểm câu trả lời (answer_score, trung bình 0.82) ổn định và cao hơn hẳn điểm truy xuất (retrieval_score, trung bình 0.51) ở hầu hết các cuốn sách. Điều này cho thấy **nút thắt của hệ thống nằm ở pha truy xuất**, chứ không phải ở khả năng diễn đạt của mô hình sinh.



Hình 4.3: Hai thành phần điểm tổng thể: điểm truy xuất so với điểm câu trả lời theo từng bộ sách.


4.5.2 Phân tích Recall@k: ảnh hưởng của số đoạn truy xuất

Đây là một trong những phát hiện quan trọng nhất của thực nghiệm. Bảng 4.7 và Hình 4.4, 4.5 cho thấy: khi tăng số đoạn truy xuất k , giá trị Recall **tăng đơn điệu**


từ 0.66 ($k = 3$) lên 0.77 ($k = 5$) và đạt 0.84 ($k = 10$). Trong khi đó, cấu hình production (chỉ giữ ≈ 3 đoạn sau bộ lọc liên quan) chỉ đạt recall 0.63.

Bảng 4.7: Recall@k (thô) theo từng bộ sách so với recall production

Bộ sách	Recall@3	Recall@5	Recall@10	Recall (prod.)
KHTN 9 CD	0.80	0.80	0.80	0.80
KHTN 7 CD	0.80	0.80	0.80	0.80
KHTN 6 CTST	0.70	0.80	0.90	0.70
KHTN 8 CTST	0.90	0.90	0.90	0.80
KHTN 8 KNTT	0.60	0.70	0.70	0.60
KHTN 8 CD	0.60	0.90	0.90	0.60
KHTN 9 CTST	0.70	0.80	0.80	0.70
KHTN 7 KNTT	0.70	0.80	1.00	0.60
KHTN 9 KNTT	0.70	0.90	0.90	0.60
KHTN 7 CTST	0.60	0.60	0.80	0.60
KHTN 6 CD	0.50	0.70	1.00	0.50
KHTN 6 KNTT	0.30	0.50	0.60	0.30
Trung bình	0.66	0.77	0.84	0.63



Hình 4.4: Recall trung bình tăng đơn điệu theo k , so với cấu hình production.




Hình 4.5: Recall@k theo từng bộ sách — k càng lớn, recall càng cao ở mọi bộ sách.

Khoảng cách giữa trần recall ($\text{Recall@10} = 0.84$) và recall production (0.63) — tức 0.21 — chính là phần recall **bị mất do khâu xếp hạng và cắt-k** của bộ truy xuất, *chứ không phải do mô hình nhúng không tìm được trang*. Nói cách khác, mô hình nhúng MiniLM gần như luôn đưa được trang vàng vào top-10, nhưng cấu hình hiện tại (giữ tối đa 3–4 đoạn sau bộ lọc liên quan) đã loại bỏ trang đúng trong khoảng 21% số trường hợp. Đây là một định hướng cải tiến rõ ràng và có thể đo lường được (sẽ thảo luận ở Mục 4.6).

4.5.3 Chất lượng câu trả lời sinh ra

Hình 4.6 tổng hợp điểm trung bình do mô hình giám khảo chấm. Mô hình Qwen2.5 đạt điểm **Độ trung thực** 4.25/5 và **Độ liên quan** 4.36/5 — mức cao, cho thấy cơ chế RAG cùng prompt nghiêm ngặt đã thành công trong việc buộc mô hình bám sát ngữ cảnh và trả lời đúng trọng tâm, hạn chế ảo giác. Điểm **Tính đúng** thấp hơn (3.76/5) phản ánh ảnh hưởng dây chuyền từ pha truy xuất: khi ngữ cảnh truy xuất thiếu trang vàng, mô hình khó cho ra đáp án hoàn toàn chính xác dù vẫn trung thực với ngữ cảnh nhận được.



Hình 4.6: Chất lượng câu trả lời của Qwen2.5 do LLM thứ hai (MiMo-v2.5-pro) chấm.

4.6 Thảo luận kết quả

Từ các số liệu thực nghiệm, có thể rút ra một số nhận định và phát hiện quan trọng:

1. **Nút thắt nằm ở khâu xếp hạng/cắt-k, không phải ở mô hình nhúng.** Như phân tích ở Mục 4.5.2, trần recall đạt 0.84 trong khi production chỉ 0.63. Việc nói số đoạn giữ lại (RETRIEVER_MAX_K) hoặc bổ sung một bước *re-ranking* (ví dụ cross-encoder) được kỳ vọng sẽ thu hẹp khoảng cách 0.21 này, qua đó kéo theo cả Tính đúng của câu trả lời.
2. **Hạn chế của mô hình nhúng với câu hỏi ngắn/trừu tượng.** MiniLM được chọn vì gọn nhẹ, nhưng với các câu hỏi mang tính khái quát, vector câu hỏi nằm gần nhiều cụm chủ đề khác nhau, khiến trang đúng đôi khi tụt khỏi top-3. Điều này thể hiện rõ ở MRR trung bình chỉ 0.51 (trang đúng thường ở hạng 2–3 thay vì hạng 1).
3. **Hiện tượng nhiễu chéo giữa các bộ sách.** Do ba bộ sách trình bày cùng một hệ thống kiến thức Sinh học THCS (tế bào, quang hợp, hô hấp, di truyền...), nhiều chủ đề trùng lặp giữa chúng. Một câu hỏi sinh từ cuốn này đôi khi được trả lời đúng bằng nội dung Sinh học tương đương trong cuốn khác. Đây là lý do Precision ở mức trang khá thấp (0.38) dù câu trả lời vẫn đúng về mặt khoa học — một điểm cần lưu ý khi diễn giải Precision trong miền dữ liệu chồng lấn.
4. **Khoảng cách giữa độ đo IR và đánh giá của giám khảo.** Nhiều câu có Recall page-level bằng 0 nhưng vẫn được giám khảo chấm Tính đúng cao. Điều này khẳng định hai pha đo lường *bổ sung* cho nhau: độ đo IR phản ánh

chất lượng định vị nguồn, còn giám khảo phản ánh chất lượng nội dung trả lời.

5. **Sai số OCR.** Một số trang có nền phức tạp hoặc chữ in nghiêng làm Tesseract nhận diện sai, gây nhiễu cho cả việc sinh câu hỏi lẫn truy xuất, ảnh hưởng tới Precision.

4.6.1 Đánh giá thủ công luồng đa phương thức

Đối với luồng truy xuất hình ảnh, việc đánh giá tự động bằng độ đo IR gặp giới hạn (ảnh không có khái niệm "trang vàng" rõ ràng như văn bản). Do đó, nhóm tiến hành đánh giá thủ công với sự tham gia của giáo viên bộ môn theo các tiêu chí: (i) hình ảnh trả về có đúng nội dung câu hỏi không; (ii) chú thích tiếng Việt do Vintern-1B sinh ra có phản ánh đúng thuật ngữ Sinh học không; (iii) giao diện hiển thị hình ảnh và trích dẫn trang sách có rõ ràng, thân thiện với học sinh THCS không. Quá trình thực nghiệm với câu hỏi dài cũng làm lộ một lỗi kỹ thuật ở bộ mã hóa văn bản của CLIP (giới hạn 77 token); lỗi này đã được khắc phục bằng cách cắt ngắn truy vấn trước khi đưa vào CLIP, giúp luồng tìm ảnh hoạt động ổn định với mọi độ dài câu hỏi.

4.6.2 Ưu điểm

- **Giảm thiểu ảo giác:** điểm Độ trung thực 4.25/5 cho thấy cơ chế RAG cùng prompt nghiêm ngặt đã buộc Qwen2.5 trả lời bám sát nội dung sách giáo khoa chính thống, hạn chế lấy thông tin thiếu kiểm chứng.
- **Phương pháp đánh giá khách quan, lặp lại được:** nhờ gắn nhãn nguồn xác định, các độ đo Precision/Recall/MRR được tính trực tiếp từ metadata mà không phụ thuộc vào cảm tính hay sự dao động của mô hình chấm.
- **Truy xuất hình ảnh trực quan:** việc kết hợp OwlViT để cắt ảnh và Vintern-1B để mô tả giúp hệ thống trả về đúng hình minh họa, tăng tính trực quan của một trợ lý ảo giáo dục.
- **Giao diện mượt mà:** ứng dụng Next.js phản hồi nhanh, tích hợp tốt với luồng stream của LangChain.

4.6.3 Hạn chế

- **Recall truy xuất ở production còn khiêm tốn (0.63):** do cấu hình giữ ít đoạn và mô hình nhúng nhẹ; cần re-ranking hoặc embedding mạnh hơn.

- **Sai số OCR** đối với công thức, chữ trên hình, vẫn cần con người rà soát (human-in-the-loop).
- **Tài nguyên phần cứng:** hệ thống cần GPU cấu hình cao (A100) để chạy mượt nhiều mô hình cùng lúc; muốn triển khai diện rộng cần nghiên cứu lượng tử hóa (quantization) để hạ chi phí.

Chương 5

KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận

Nghiên cứu "Xây dựng trợ lý ảo thông minh dựa trên RAG hỗ trợ dạy và học môn Sinh học tại các trường trung học cơ sở" đã hoàn thành tốt đẹp các mục tiêu đặt ra. Báo cáo chuyên đề tốt nghiệp này đã trình bày một cách hệ thống từ cơ sở lý thuyết, kiến trúc hệ thống, cho đến các phương pháp triển khai thực tế.

Những kết quả nổi bật mà đề tài đạt được bao gồm:

1. Xây dựng thành công quy trình ETL hoàn chỉnh để số hóa, làm sạch và phân mảnh nội dung Sinh học từ 12 bộ sách giáo khoa Khoa học tự nhiên lớp 6, 7, 8, 9 của ba nhà xuất bản (Kết nối tri thức với cuộc sống, Chân trời sáng tạo, Cánh diều). Đặc biệt, hệ thống đã giải quyết được bài toán khó là tách bạch và tự động sinh chú thích (caption) cho các hình ảnh minh họa Sinh học trong sách nhờ mô hình OwlViT và Vintern-1B.
2. Triển khai thành công kiến trúc Multi-modal RAG kết hợp cơ sở dữ liệu ChromaDB, cho phép truy xuất đồng thời cả lý thuyết văn bản và hình ảnh trực quan.
3. Tích hợp mô hình ngôn ngữ lớn Qwen2.5-3B-Instruct nhằm sinh ra các câu trả lời tự nhiên, chính xác, dựa hoàn toàn vào dữ liệu chính thống, khắc phục được triệt để nhược điểm sinh thông tin sai lệch (hallucination) của chatbot truyền thống.
4. Hoàn thiện giao diện tương tác trên nền tảng web (Frontend) bằng Next.js, tạo ra môi trường học tập thân thiện, hiện đại, hỗ trợ hiệu quả cho quá trình tự học của học sinh và công tác giảng dạy của giáo viên.

5. Thiết lập một khung đánh giá định lượng khách quan với 12 bộ dữ liệu kiểm thử có gắn nhãn nguồn (120 câu hỏi). Kết quả thực nghiệm cho thấy câu trả lời của hệ thống đạt độ trung thực 4,25/5 và độ liên quan 4,36/5 (do một mô hình LLM thứ hai chấm độc lập), khẳng định hiệu quả của cơ chế RAG trong việc hạn chế ảo giác; đồng thời phân tích Recall@k chỉ ra rõ tiềm năng cải thiện ở pha truy xuất (recall trần đạt 0,84 so với 0,63 ở cấu hình hiện tại).

5.2 Hạn chế của đề tài

Bên cạnh những kết quả đạt được, quá trình thực hiện đề tài vẫn còn một số điểm giới hạn:

- Việc nạp số lượng lớn dữ liệu từ 12 quyển sách với cấu trúc hình ảnh đa dạng tạo ra thách thức lớn đối với quá trình tinh chỉnh tham số truy xuất. Hiện tại, độ chính xác tìm kiếm hình ảnh phụ thuộc nhiều vào chất lượng mô tả tự động của Vintern-1B.
- Quá trình OCR văn bản từ PDF đôi chỗ còn sai sót đối với các công thức hóa học, sinh học hoặc chữ viết tay trên hình, đòi hỏi sự can thiệp thủ công của con người (human-in-the-loop) để chỉnh sửa metadata trước khi đưa vào cơ sở dữ liệu.
- Yêu cầu về cấu hình phần cứng (đặc biệt là GPU) còn khá cao, gây khó khăn cho việc đóng gói và triển khai hệ thống trên các máy tính thông thường tại phòng tin học của các trường THCS.

5.3 Hướng phát triển tương lai

Để hệ thống trợ lý ảo ngày càng hoàn thiện và có khả năng ứng dụng rộng rãi, hướng phát triển trong thời gian tới sẽ tập trung vào các hạng mục sau:

- **Nâng cao recall của pha truy xuất:** Dựa trên phát hiện về khoảng cách giữa recall trần (0,84) và recall production (0,63), hướng ưu tiên là bổ sung bước *re-ranking* (ví dụ cross-encoder) và nới rộng số đoạn ứng viên, nhằm đưa trang đúng lên đầu danh sách mà vẫn giữ được khả năng lọc nhiễu của cổng liên quan. Song song, có thể thay thế mô hình nhúng MiniLM bằng mô hình mạnh hơn để cải thiện thứ hạng với các câu hỏi ngắn, trừu tượng.

- **Cải thiện chất lượng Vector Database:** Ứng dụng các cơ chế đánh trọng số từ khóa, phân loại câu hỏi (query routing) dựa trên khối lớp (6, 7, 8, 9) để tăng độ chính xác trong việc truy xuất nội dung chuyên biệt cho từng khối học.
- **Lượng tử hóa mô hình (Quantization):** Nghiên cứu áp dụng các kỹ thuật lượng tử hóa (như GGUF, AWQ, GPTQ) để giảm độ chính xác biểu diễn trọng số, qua đó nén kích thước mô hình ngôn ngữ lớn và cho phép trợ lý ảo hoạt động trơn tru trên các máy chủ có cấu hình thấp hơn hoặc thậm chí là máy tính cá nhân.
- **Tính năng đánh giá người học:** Phát triển thêm khả năng cho phép LLM tự động sinh ra các bài trắc nghiệm (quiz) dựa trên nội dung bài học để kiểm tra kiến thức học sinh ngay sau khi tra cứu thông tin.
- **Triển khai thực tế và lấy ý kiến phản hồi:** Đưa hệ thống vào thử nghiệm thực tế tại một số trường THCS nhằm thu thập dữ liệu hành vi người dùng, từ đó tinh chỉnh hệ thống ngày một thông minh và sát với nhu cầu thực tiễn hơn.

TÀI LIỆU THAM KHẢO

- [1] Stanislaw Antol et al. “VQA: Visual Question Answering”. In: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. 2015, pp. 2425–2433. arXiv: 1505.00468. url: <https://arxiv.org/abs/1505.00468>.
- [2] Akari Asai et al. “Self-RAG: Learning to Retrieve, Generate, and Critique through Self-Reflection”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2024. arXiv: 2310.11511. url: <https://arxiv.org/abs/2310.11511>.
- [3] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. “Neural Machine Translation by Jointly Learning to Align and Translate”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2015. arXiv: 1409.0473. url: <https://arxiv.org/abs/1409.0473>.
- [4] Yoshua Bengio et al. “A Neural Probabilistic Language Model”. In: *Journal of Machine Learning Research* 3 (2003), pp. 1137–1155. url: <https://www.jmlr.org/papers/volume3/bengio03a/bengio03a.pdf>.
- [5] Rishi Bommasani et al. “On the Opportunities and Risks of Foundation Models”. In: *arXiv preprint arXiv:2108.07258* (2021). arXiv: 2108.07258. url: <https://arxiv.org/abs/2108.07258>.
- [6] Tom B Brown et al. “Language Models are Few-Shot Learners”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 1877–1901. arXiv: 2005.14165. url: <https://arxiv.org/abs/2005.14165>.
- [7] Cao Cự Giác (Tổng chủ biên). *Khoa học tự nhiên 6 – Bộ Chân trời sáng tạo*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2021. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-lop-6-chan-troi-sang-tao2/> (visited on 06/07/2026).
- [8] Cao Cự Giác (Tổng chủ biên). *Khoa học tự nhiên 7 – Bộ Chân trời sáng tạo*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2022. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-7-chan-troi-sang-tao/> (visited on 06/07/2026).

- [9] Cao Cự Giác (Tổng chủ biên). *Khoa học tự nhiên 8 – Bộ Chân trời sáng tạo*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2023. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-8-chan-troi-sang-tao/> (visited on 06/07/2026).
- [10] Cao Cự Giác (Tổng chủ biên). *Khoa học tự nhiên 9 – Bộ Chân trời sáng tạo*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2024. url: <http://thcsxuantan.edu.vn/trang-chu/lien-doi-xuan-tan/sach-dien-tu/sach-giao-khoa-khoa-hoc-tu-nhien-9-chan-troi-sang-tao.html> (visited on 06/07/2026).
- [11] Harrison Chase. *LangChain: Building applications with LLMs through composability*. <https://github.com/langchain-ai/langchain>. Phần mềm mã nguồn mở. 2022.
- [12] Chroma. *Chroma: the open-source AI application database (embeddings)*. <https://www.trychroma.com>. Phần mềm mã nguồn mở. 2023.
- [13] Jacob Devlin et al. “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding”. In: *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL-HLT)*. 2019, pp. 4171–4186. arXiv: 1810.04805. url: <https://arxiv.org/abs/1810.04805>.
- [14] Alexey Dosovitskiy et al. “An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale”. In: *Proceedings of the International Conference on Learning Representations (ICLR)*. 2021. arXiv: 2010.11929. url: <https://arxiv.org/abs/2010.11929>.
- [15] Shahul Es et al. “RAGAS: Automated Evaluation of Retrieval Augmented Generation”. In: *Proceedings of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL): System Demonstrations*. 2024, pp. 150–158. arXiv: 2309.15217. url: <https://arxiv.org/abs/2309.15217>.
- [16] Yunfan Gao et al. “Retrieval-Augmented Generation for Large Language Models: A Survey”. In: *arXiv preprint arXiv:2312.10997* (2023). arXiv: 2312.10997. url: <https://arxiv.org/abs/2312.10997>.
- [17] Kelvin Guu et al. “REALM: Retrieval-Augmented Language Model Pre-Training”. In: *Proceedings of the 37th International Conference on Machine Learning (ICML)*. 2020, pp. 3929–3938. arXiv: 2002.08909. url: <https://arxiv.org/abs/2002.08909>.

- [18] Lei Huang et al. “A Survey on Hallucination in Large Language Models: Principles, Taxonomy, Challenges, and Open Questions”. In: *arXiv preprint arXiv:2311.05232* (2023). arXiv: 2311.05232. url: <https://arxiv.org/abs/2311.05232>.
- [19] Gautier Izacard and Edouard Grave. “Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering”. In: *Proceedings of the 16th Conference of the European Chapter of the Association for Computational Linguistics (EACL)*. 2021, pp. 874–880. arXiv: 2007.01282. url: <https://arxiv.org/abs/2007.01282>.
- [20] Ziwei Ji et al. “Survey of Hallucination in Natural Language Generation”. In: *ACM Computing Surveys* 55.12 (2023), pp. 1–38. arXiv: 2202.03629. url: <https://arxiv.org/abs/2202.03629>.
- [21] Jeff Johnson, Matthijs Douze, and Hervé Jégou. “Billion-scale similarity search with GPUs”. In: *IEEE Transactions on Big Data* 7.3 (2021), pp. 535–547. arXiv: 1702.08734. url: <https://arxiv.org/abs/1702.08734>.
- [22] Jared Kaplan et al. “Scaling Laws for Neural Language Models”. In: *arXiv preprint arXiv:2001.08361* (2020). arXiv: 2001.08361. url: <https://arxiv.org/abs/2001.08361>.
- [23] Vladimir Karpukhin et al. “Dense Passage Retrieval for Open-Domain Question Answering”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2020, pp. 6769–6781. arXiv: 2004.04758. url: <https://arxiv.org/abs/2004.04758>.
- [24] Enkelejda Kasneci et al. “ChatGPT for good? On opportunities and challenges of large language models for education”. In: *Learning and Individual Differences* 103 (2023), p. 102274. doi: 10.1016/j.lindif.2023.102274.
- [25] Yann LeCun, Yoshua Bengio, and Geoffrey Hinton. “Deep learning”. In: *Nature* 521.7553 (2015), pp. 436–444. doi: 10.1038/nature14539.
- [26] Patrick Lewis et al. “Retrieval-augmented generation for knowledge-intensive nlp tasks”. In: *Advances in Neural Information Processing Systems* 33 (2020), pp. 9459–9474. arXiv: 2005.11401. url: <https://arxiv.org/abs/2005.11401>.
- [27] Junnan Li et al. “BLIP: Bootstrapping Language-Image Pre-training for Unified Vision-Language Understanding and Generation”. In: *International Conference on Machine Learning (ICML)*. 2022, pp. 12888–12900. arXiv: 2201.12086. url: <https://arxiv.org/abs/2201.12086>.

- [28] Chin-Yew Lin. “ROUGE: A Package for Automatic Evaluation of Summaries”. In: *Text Summarization Branches Out: Proceedings of the ACL-04 Workshop*. 2004, pp. 74–81. url: <https://aclanthology.org/W04-1013.pdf>.
- [29] Yang Liu et al. “G-Eval: NLG Evaluation using GPT-4 with Better Human Alignment”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing (EMNLP)*. 2023, pp. 2511–2522. arXiv: 2303.16634. url: <https://arxiv.org/abs/2303.16634>.
- [30] Mai Sỹ Tuấn (Tổng chủ biên). *Khoa học tự nhiên 6 – Bộ Cánh Diều*. Hà Nội: Nhà xuất bản Đại học Sư phạm, 2021. url: <https://loigiaihay.com/sgk-khoa-hoc-tu-nhien-6-pdf-khoa-hoc-tu-nhien-6-can-h-dieu-a155409.html> (visited on 06/07/2026).
- [31] Mai Sỹ Tuấn (Tổng chủ biên). *Khoa học tự nhiên 7 – Bộ Cánh Diều*. Hà Nội: Nhà xuất bản Đại học Sư phạm, 2022. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-7-can-h-dieu/#1> (visited on 06/07/2026).
- [32] Mai Sỹ Tuấn (Tổng chủ biên). *Khoa học tự nhiên 8 – Bộ Cánh Diều*. Hà Nội: Nhà xuất bản Đại học Sư phạm, 2023. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-8-can-h-dieu/> (visited on 06/07/2026).
- [33] Mai Sỹ Tuấn (Tổng chủ biên). *Khoa học tự nhiên 9 – Bộ Cánh Diều*. Hà Nội: Nhà xuất bản Đại học Sư phạm, 2024. url: <https://loigiaihay.com/sgk-khoa-hoc-tu-nhien-9-pdf-khoa-hoc-tu-nhien-9-can-h-dieu-a155092.html> (visited on 06/07/2026).
- [34] Yu A Malkov and Dmitry A Yashunin. “Efficient and robust approximate nearest neighbor search using Hierarchical Navigable Small World graphs”. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 42.4 (2020), pp. 824–836. arXiv: 1603.09320. url: <https://arxiv.org/abs/1603.09320>.
- [35] Tomas Mikolov et al. “Efficient Estimation of Word Representations in Vector Space”. In: *Proceedings of the International Conference on Learning Representations (ICLR) Workshop* (2013). arXiv: 1301.3781. url: <https://arxiv.org/abs/1301.3781>.
- [36] Matthias Minderer et al. “Simple Open-Vocabulary Object Detection with Vision Transformers”. In: *European Conference on Computer Vision (ECCV)*. 2022. arXiv: 2205.06230. url: <https://arxiv.org/abs/2205.06230>.

- [37] Dat Quoc Nguyen and Anh Tuan Nguyen. “PhoBERT: Pre-trained language models for Vietnamese”. In: *Findings of the Association for Computational Linguistics: EMNLP 2020*. 2020, pp. 1037–1042. arXiv: 2003.00744. url: <https://arxiv.org/abs/2003.00744>.
- [38] Long Ouyang et al. “Training language models to follow instructions with human feedback”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 35. 2022, pp. 27730–27744. arXiv: 2203.02155. url: <https://arxiv.org/abs/2203.02155>.
- [39] Kishore Papineni et al. “BLEU: a Method for Automatic Evaluation of Machine Translation”. In: *Proceedings of the 40th Annual Meeting of the Association for Computational Linguistics (ACL)*. 2002, pp. 311–318. doi: 10.3115/1073083.1073135.
- [40] Alibaba Group Qwen Team. “Qwen2.5 Technical Report”. In: (2024). arXiv: 2412.15115. url: <https://arxiv.org/abs/2412.15115>.
- [41] Alec Radford et al. “Learning transferable visual models from natural language supervision”. In: *International Conference on Machine Learning (ICML)*. 2021. arXiv: 2103.00020. url: <https://arxiv.org/abs/2103.00020>.
- [42] Nils Reimers and Iryna Gurevych. “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks”. In: *Proceedings of EMNLP-IJCNLP (2019)*. arXiv: 1908.10084. url: <https://arxiv.org/abs/1908.10084>.
- [43] Stephen Robertson and Hugo Zaragoza. “The Probabilistic Relevance Framework: BM25 and Beyond”. In: *Foundations and Trends in Information Retrieval* 3.4 (2009), pp. 333–389. doi: 10.1561/15000000019. url: https://www.staff.city.ac.uk/~sbrp622/papers/foundations_bm25_review.pdf.
- [44] Ray Smith. “An Overview of the Tesseract OCR Engine”. In: *Ninth International Conference on Document Analysis and Recognition (ICDAR)*. Vol. 2. IEEE. 2007, pp. 629–633. doi: 10.1109/ICDAR.2007.4376991.
- [45] Ilya Sutskever, Oriol Vinyals, and Quoc V Le. “Sequence to Sequence Learning with Neural Networks”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 27. 2014. arXiv: 1409.3215. url: <https://arxiv.org/abs/1409.3215>.
- [46] Hugo Touvron et al. “LLaMA: Open and Efficient Foundation Language Models”. In: *arXiv preprint arXiv:2302.13971* (2023). arXiv: 2302.13971. url: <https://arxiv.org/abs/2302.13971>.

- [47] Ashish Vaswani et al. “Attention is all you need”. In: *Advances in neural information processing systems* 30 (2017). arXiv: 1706.03762. url: <https://arxiv.org/abs/1706.03762>.
- [48] Ellen M Voorhees. “The TREC-8 Question Answering Track Report”. In: *Proceedings of the 8th Text REtrieval Conference (TREC-8)*. 1999, pp. 77–82. url: https://trec.nist.gov/pubs/trec8/papers/qa_report.pdf.
- [49] Vũ Văn Hùng (Tổng chủ biên). *Khoa học tự nhiên 6 – Bộ Kết nối tri thức với cuộc sống*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2021. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-lop-6-ket-noi-tri-thuc/> (visited on 06/07/2026).
- [50] Vũ Văn Hùng (Tổng chủ biên). *Khoa học tự nhiên 7 – Bộ Kết nối tri thức với cuộc sống*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2022. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-7-ket-noi-tri-thuc/> (visited on 06/07/2026).
- [51] Vũ Văn Hùng (Tổng chủ biên). *Khoa học tự nhiên 8 – Bộ Kết nối tri thức với cuộc sống*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2023. url: <https://giaokhoaonline.com/khoa-hoc-tu-nhien-8-ket-noi-tri-thuc/> (visited on 06/07/2026).
- [52] Vũ Văn Hùng (Tổng chủ biên). *Khoa học tự nhiên 9 – Bộ Kết nối tri thức với cuộc sống*. Hà Nội: Nhà xuất bản Giáo dục Việt Nam, 2024. url: <http://thcsxuantan.edu.vn/trang-chu/lien-doi-xuan-tan/sach-dien-tu/sach-giao-khoa-khoa-hoc-tu-nhien-9-ket-noi-tri-thuc.html?categoryId=14810277> (visited on 06/07/2026).
- [53] Wenhui Wang et al. “MiniLM: Deep Self-Attention Distillation for Task-Agnostic Compression of Pre-Trained Transformers”. In: *Advances in Neural Information Processing Systems (NeurIPS)*. Vol. 33. 2020, pp. 5776–5788. arXiv: 2002.10957. url: <https://arxiv.org/abs/2002.10957>.
- [54] Jason Wei et al. “Emergent Abilities of Large Language Models”. In: *Transactions on Machine Learning Research (TMLR)* (2022). arXiv: 2206.07682. url: <https://arxiv.org/abs/2206.07682>.
- [55] Thomas Wolf et al. “Transformers: State-of-the-Art Natural Language Processing”. In: *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP): System Demonstrations*. 2020, pp. 38–45. arXiv: 1910.03771. url: <https://arxiv.org/abs/1910.03771>.

- [56] Olaf Zawacki-Richter et al. “Systematic review of research on artificial intelligence applications in higher education – where are the educators?” In: *International Journal of Educational Technology in Higher Education* 16.1 (2019), p. 39. doi: 10.1186/s41239-019-0171-0.
- [57] Wayne Xin Zhao et al. “A Survey of Large Language Models”. In: *arXiv preprint arXiv:2303.18223* (2023). arXiv: 2303.18223. url: <https://arxiv.org/abs/2303.18223>.
- [58] Lianmin Zheng et al. “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena”. In: *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*. Vol. 36. 2023. arXiv: 2306.05685. url: <https://arxiv.org/abs/2306.05685>.